

SEGMENTASI POLA TRANSAKSI PELANGGAN TOKO ONLINE MENGUNAKAN K-MEANS CLUSTERING



Dosen Pengampu:
Ir. I Made Dwi Putra Asana, S.Kom., M.T.

Disusun Oleh:

Alexander Noventino Lambut	2401010802
I Gede Agus Arta Pratama Putra	2401010252
Rivaldi Kinaryoadi	240101024

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI DAN INFORMATIKA
INSTITUT BISNIS DAN TEKNOLOGI INDONESIA
DENPASAR
2026**

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadapan Tuhan Yang Maha Esa karena atas rahmat-Nya laporan Ujian Akhir Semester mata kuliah Data Analytics ini dapat disusun dengan baik. Laporan ini membahas penerapan metode data mining berbasis CRISP-DM untuk melakukan segmentasi pola transaksi pelanggan toko online menggunakan algoritma K-Means Clustering.

Penyusunan laporan ini bertujuan untuk mendokumentasikan seluruh proses proyek mulai dari Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, hingga Deployment. Laporan ini juga telah disinkronkan dengan notebook final sehingga kode program, output tabel, visualisasi, file model, dan artefak deployment yang ditampilkan pada laporan sesuai dengan hasil proses pada Google Colab.

Penulis menyadari bahwa laporan ini masih dapat disempurnakan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan agar laporan dan implementasi proyek dapat menjadi lebih baik.

Denpasar, Rabu 3 Juli 2026

Penulis

BAB I

BUSINESS UNDERSTANDING

1.1 Latar Belakang

Perkembangan teknologi informasi dan internet telah mendorong pertumbuhan transaksi pada platform toko online. Aktivitas transaksi yang berlangsung secara terus-menerus menghasilkan data dalam jumlah besar yang memuat informasi mengenai karakteristik pelanggan dan perilaku transaksi. Data tersebut dapat dimanfaatkan untuk memperoleh wawasan yang berguna dalam mendukung pengambilan keputusan bisnis.

Besarnya volume data transaksi sering kali menyulitkan perusahaan dalam memahami pola transaksi secara manual. Setiap transaksi memiliki karakteristik yang berbeda, seperti usia pelanggan, status pernikahan, status pekerjaan, metode pembayaran, sumber referral, serta jumlah pengeluaran. Perbedaan karakteristik tersebut menyebabkan pola transaksi yang terbentuk menjadi semakin kompleks dan membutuhkan pendekatan analitis agar dapat dipahami dengan lebih objektif.

Salah satu pendekatan yang dapat digunakan untuk memahami pola transaksi adalah teknik clustering dalam data mining. Clustering merupakan metode unsupervised learning yang bertujuan mengelompokkan data berdasarkan tingkat kemiripan karakteristik tanpa memerlukan variabel target atau label tertentu. Dengan melakukan clustering, transaksi yang memiliki karakteristik serupa dapat dikelompokkan ke dalam satu kluster sehingga memudahkan proses analisis dan interpretasi.

Pada penelitian ini digunakan dataset Online Store Customer Transactions yang berisi 1.000.000 data transaksi pelanggan toko online selama periode 2018 sampai 2025. Setiap baris pada dataset merepresentasikan satu transaksi, bukan satu pelanggan unik, sehingga fokus penelitian ini adalah segmentasi pola transaksi pelanggan.

1.2 Rumusan Masalah

1. Bagaimana mengelompokkan pola transaksi pelanggan toko online berdasarkan karakteristik demografis dan nilai pengeluaran menggunakan metode clustering?
2. Bagaimana menentukan jumlah kluster yang optimal pada data transaksi pelanggan?
3. Bagaimana karakteristik masing-masing kluster yang terbentuk dari proses clustering?
4. Bagaimana hasil segmentasi transaksi dapat dimanfaatkan untuk mendukung pengambilan keputusan bisnis?

1.3 Tujuan Penelitian

1. Mengelompokkan transaksi pelanggan toko online berdasarkan kemiripan karakteristik menggunakan metode K-Means Clustering.
2. Menentukan jumlah kluster yang optimal menggunakan metode evaluasi clustering.
3. Mengidentifikasi karakteristik setiap kluster yang terbentuk melalui proses profiling cluster.
4. Menghasilkan informasi mengenai pola transaksi pelanggan yang dapat digunakan sebagai pendukung pengambilan keputusan bisnis.

1.4 Manfaat Penelitian

1.4.1 Manfaat Akademis

1. Menambah pemahaman mengenai penerapan teknik clustering pada bidang data mining.
2. Menjadi contoh implementasi framework CRISP-DM dalam penyelesaian permasalahan segmentasi data.
3. Memberikan referensi bagi penelitian selanjutnya yang berkaitan dengan segmentasi transaksi menggunakan metode clustering.

1.4.2 Manfaat Praktis

1. Membantu perusahaan memahami pola transaksi pelanggan berdasarkan karakteristik transaksi yang dimiliki.
2. Membantu proses identifikasi kelompok transaksi dengan nilai pengeluaran dan karakteristik yang berbeda.
3. Mendukung penyusunan strategi pemasaran dan layanan yang lebih tepat sasaran.
4. Memberikan informasi yang dapat digunakan sebagai dasar pengambilan keputusan bisnis.

1.5 Kriteria Keberhasilan

1. Model K-Means Clustering mampu membentuk beberapa klaster berdasarkan karakteristik transaksi pelanggan.
2. Jumlah klaster optimal dapat ditentukan menggunakan Elbow Method, Silhouette Score, dan Davies-Bouldin Index.
3. Setiap klaster memiliki karakteristik yang dapat diinterpretasikan secara jelas melalui profiling cluster.
4. Hasil clustering dapat divisualisasikan dan diimplementasikan pada aplikasi deployment sederhana berbasis Streamlit.

BAB II

DATA UNDERSTANDING

Tahap Data Understanding bertujuan untuk memahami karakteristik data sebelum memasuki tahap Data Preparation. Seluruh kode dan output pada BAB II mengikuti notebook final yang digunakan sebagai bukti di Google Colab.

2.1 Memuat Dataset dan Memeriksa Dimensi Data

```
# =====
# KODE 2.1 MEMUAT DATASET DAN MEMERIKSA DIMENSI DATA
# =====
dataset_path = "customer_spending_1M_2018_2025.csv"

if not os.path.exists(dataset_path):
    local_path = "/mnt/data/customer_spending_1M_2018_2025.csv"
    if os.path.exists(local_path):
        dataset_path = local_path

if not os.path.exists(dataset_path):
    try:
        from google.colab import files
        print("Upload file customer_spending_1M_2018_2025.csv")
        uploaded = files.upload()
        dataset_path = list(uploaded.keys())[0]
    except Exception:
        raise FileNotFoundError("Dataset belum ditemukan. Upload customer_spending_1M_2018_2025.csv terlebih dahulu.")

df = pd.read_csv(dataset_path)
shape_awal = df.shape
print("Dataset berhasil dimuat.")
print("Ukuran dataset:", df.shape)
display(df.head())
```

Kode 2.1 Memuat Dataset dan Memeriksa Dimensi Data

Output: Dataset berhasil dimuat dengan ukuran dataset (1.000.000, 12). Lima data pertama ditampilkan pada tabel berikut.

Tabel 2.1 Lima Data Pertama Dataset

	Transaction_ID	Transaction_date	Gender	Age	Marital_status	State_names	Segment	Employees_status	Payment_method	Referral	Amount_spent
0	1000	2018-01-01T00:04:00.000000	Female	39.0	Single	Oklahoma	Platinum	Unemployment	Card	0.0	1557.50
1	1001	2018-01-01T00:06:00.000000	Male	34.0	Married	Hawaii	Basic	workers	PayPal	1.0	153.55
2	1002	2018-01-01T00:14:00.000000	Female	53.0	Married	Iowa	Basic	self-employed	PayPal	1.0	2640.96
3	1003	2018-01-01T00:23:00.000000	Male	33.0	Married	Wisconsin	Basic	self-employed	Card	1.0	293.58
4	1004	2018-01-01T00:25:00.000000	Female	36.0	Married	Texas	Platinum	Employees	Card	0.0	1608.01

2.2 Pemeriksaan Tipe Data Atribut

```
# =====
# KODE 2.2 PEMERIKSAAN TIPE DATA ATRIBUT
# =====
print("Tipe data atribut:")
display(df.dtypes.to_frame("Tipe Data"))

info_dataset = pd.DataFrame({
    "Komponen": ["Nama Dataset", "Sumber", "Jumlah Baris", "Jumlah Kolom", "Periode Data", "Jenis Data", "Teknik Data Mining", "Algoritma"],
    "Keterangan": ["Online Store Customer Transactions (1M Rows)", "Kaggle", f"{df.shape[0]:,}", df.shape[1], "2018-2025", "Data transaksi pelanggan toko online", "Clustering", "K-Means Clustering"]
})
display(info_dataset)
```

Kode 2.2 Pemeriksaan Tipe Data Atribut

Tabel 2.2 Tipe Data Atribut

Tipe data atribut:	
	Tipe Data
Transaction_ID	int64
Transaction_date	object
Gender	object
Age	float64
Marital_status	object
State_names	object
Segment	object
Employees_status	object
Payment_method	object
Referral	float64
Amount_spent	float64

Tabel 2.3 Informasi Dataset

	Komponen	Keterangan
0	Nama Dataset	Online Store Customer Transactions (1M Rows)
1	Sumber	Kaggle
2	Jumlah Baris	1,000,000
3	Jumlah Kolom	11
4	Periode Data	2018-2025
5	Jenis Data	Data transaksi pelanggan toko online
6	Teknik Data Mining	Clustering
7	Algoritma	K-Means Clustering

Hasil pemeriksaan menunjukkan bahwa dataset memiliki 1.000.000 baris dan 11 kolom. Transaction_date terbaca sebagai object, sedangkan Age, Referral, dan Amount_spent terbaca sebagai atribut numerik.

2.3 Statistik Deskriptif Atribut Numerik

```
# =====
# KODE 2.3 STATISTIK DESKRIPTIF ATRIBUT NUMERIK
# =====
kolom_numerik_awal = ["Age", "Referral", "Amount_spent"]
statistik_numerik = df[kolom_numerik_awal].describe().round(2)
display(statistik_numerik)
```

Kode 2.3 Statistik Deskriptif Atribut Numerik

Tabel 2.4 Statistik Deskriptif Atribut Numerik

	Age	Referral	Amount_spent
count	983346.00	938188.00	903935.00
mean	46.65	0.65	1416.13
std	18.18	0.48	878.12
min	15.00	0.00	2.09
25%	32.00	0.00	677.36
50%	47.00	1.00	1332.48
75%	62.00	1.00	2037.59
max	78.00	1.00	2999.98

Atribut Age memiliki rentang 15 sampai 78 tahun. Atribut Amount_spent memiliki rentang 2,09 sampai 2.999,98 sehingga perlu distandardisasi sebelum digunakan pada K-Means.

2.4 Distribusi Atribut Kategorikal

```
# =====
# KODE 2.4 DISTRIBUSI ATRIBUT KATEGORIKAL
# =====
kolom_kategorikal_awal = ["Gender", "Marital_status", "Employees_status", "Payment_method", "Segment"]
for kolom in kolom_kategorikal_awal:
    print(f"\nDistribusi kategori: {kolom}")
    display(df[kolom].value_counts(dropna=False).to_frame("Jumlah"))
```

Kode 2.4 Distribusi Atribut Kategorikal

Tabel 2.5 Distribusi Atribut Kategorikal

Distribusi kategori: Gender

	Jumlah
Gender	
Female	539831
Male	449117
NaN	11052

Distribusi kategori: Marital_status

	Jumlah
Marital_status	
Married	586105
Single	413895

Distribusi kategori: Employees_status

	Jumlah
Employees_status	
Employees	377080
workers	317770
self-employed	193705
Unemployment	101220
NaN	10225

Distribusi kategori: Payment_method

	Jumlah
Payment_method	
PayPal	464185
Card	298345
Other	237470

Distribusi kategori: Segment

	Jumlah
Segment	
Basic	452546
Silver	194779
Platinum	176269
Gold	98415
Missing	77991

Atribut	Kategori	Jumlah	Persentase (%)
Gender	Female	539,831	53.98
Gender	Male	449,117	44.91
Gender	NaN	11,052	1.11
Marital_status	Married	586,105	58.61
Marital_status	Single	413,895	41.39
Employees_status	Employees	377,080	37.71
Employees_status	workers	317,770	31.78
Employees_status	self-employed	193,705	19.37
Employees_status	Unemployment	101,220	10.12
Employees_status	NaN	10,225	1.02
Payment_method	PayPal	464,185	46.42
Payment_method	Card	298,345	29.83
Payment_method	Other	237,470	23.75
Segment	Basic	452,546	45.25
Segment	Silver	194,779	19.48
Segment	Platinum	176,269	17.63
Segment	Gold	98,415	9.84
Segment	Missing	77,991	7.80

Atribut Segment merupakan kategori bawaan dataset sehingga tidak digunakan sebagai fitur training. Atribut ini tetap disimpan untuk membantu profiling pada tahap evaluasi.

2.5 Pemeriksaan Kualitas Data Awal

```
# =====
# KODE 2.5 PEMERIKSAAN KUALITAS DATA AWAL
# =====
missing_awal = pd.DataFrame({
    "Missing Value": df.isnull().sum(),
    "Persentase (%)": (df.isnull().sum() / len(df) * 100).round(2)
})
missing_awal = missing_awal[missing_awal["Missing Value"] > 0].sort_values("Missing Value", ascending=False)
print("Missing value awal:")
display(missing_awal)

plt.figure(figsize=(8, 4))
missing_awal["Missing Value"].plot(kind="bar")
plt.title("Jumlah Missing Value per Atribut")
plt.xlabel("Atribut")
plt.ylabel("Jumlah Missing Value")
plt.xticks(rotation=45, ha="right")
plt.tight_layout()
plt.savefig("fig_missing_values.png", dpi=180)
plt.show()

validasi_awal = {
    "Baris duplikat identik": int(df.duplicated().sum()),
    "Transaction_ID unik": int(df["Transaction_ID"].nunique()),
    "Transaction_ID duplikat": int(df["Transaction_ID"].duplicated().sum()),
}
```



```

}

dff["Transaction_date_parsed"] = pd.to_datetime(dff["Transaction_date"], errors="coerce")
validasi_awal["Tanggal gagal parsing"] = int(dff["Transaction_date_parsed"].isna().sum())
validasi_awal["Tanggal awal"] = dff["Transaction_date_parsed"].min()
validasi_awal["Tanggal akhir"] = dff["Transaction_date_parsed"].max()
validasi_awal["Jumlah State_names"] = int(dff["State_names"].nunique(dropna=True))
validasi_awal["Segment bernilai Missing"] = int((dff["Segment"] == "Missing").sum())
validasi_awal["Nilai unik Referral"] = sorted(dff["Referral"].dropna().unique().tolist())


display(pd.DataFrame(list(validasi_awal.items()), columns=["Pemeriksaan", "Hasil"]))

```

Kode 2.5 Pemeriksaan Kualitas Data Awal

Tabel 2.6 Missing Value Awal

Missing value awal:		
	Missing Value	Persentase (%)
Amount_spent	96065	9.61
Referral	61812	6.18
Age	16654	1.67
Gender	11052	1.11
Employees_status	10225	1.02



Gambar 2.1 Visualisasi Missing Value per Atribut

Tabel 2.7 Validasi Kualitas Data Awal

	Pemeriksaan	Hasil
0	Baris duplikat identik	0
1	Transaction_ID unik	1000000
2	Transaction_ID duplikat	0
3	Tanggal gagal parsing	0
4	Tanggal awal	2018-01-01 00:04:00
5	Tanggal akhir	2025-01-30 23:57:00
6	Jumlah State_names	50
7	Segment bernilai Missing	77991
8	Nilai unik Referral	[0.0, 1.0]

Output menunjukkan bahwa missing value terbesar terdapat pada Amount_spent sebanyak 96.065 baris. Tidak terdapat baris duplikat identik dan Transaction_ID bersifat unik.

2.6 Pemeriksaan Outlier Awal dengan IQR dan Boxplot

```
# =====
# KODE 2.6 PEMERIKSAAN OUTLIER AWAL DENGAN IQR DAN BOXPLOT
# =====
def cek_outlier_iqr(dataframe, kolom):
    data = dataframe[kolom].dropna()
    q1 = data.quantile(0.25)
    q3 = data.quantile(0.75)
    iqr = q3 - q1
    batas_bawah = q1 - 1.5 * iqr
    batas_atas = q3 + 1.5 * iqr
    jumlah_outlier = ((data < batas_bawah) | (data > batas_atas)).sum()
    return {
        "Atribut": kolom,
        "Q1": round(q1, 2),
        "Q3": round(q3, 2),
        "IQR": round(iqr, 2),
        "Batas Bawah": round(batas_bawah, 2),
        "Batas Atas": round(batas_atas, 2),
        "Jumlah Outlier": int(jumlah_outlier)
    }


outlier_awal = pd.DataFrame([cek_outlier_iqr(df, "Age"), cek_outlier_iqr(df, "Amount_spent")])
display(outlier_awal)

plt.figure(figsize=(10, 4))
plt.boxplot(df["Amount_spent"].dropna(), vert=False)
plt.title("Boxplot Distribusi Pengeluaran (Amount_spent)")
plt.xlabel("Nilai Amount_spent")
plt.grid(axis="x", linestyle="--", alpha=0.7)
plt.tight_layout()
plt.savefig("fig_amount_boxplot.png", dpi=180)
plt.show()
```

Kode 2.6 Pemeriksaan Outlier Awal dengan IQR dan Boxplot

Tabel 2.8 Hasil Pemeriksaan Outlier Awal

	Atribut	Q1	Q3	IQR	Batas Bawah	Batas Atas	Jumlah Outlier
0	Age	32.00	62.00	30.00	-13.00	107.00	0
1	Amount_spent	677.36	2037.59	1360.23	-1362.98	4077.94	0



Gambar 2.2 Boxplot Distribusi Amount_spent

Berdasarkan IQR, tidak ditemukan outlier pada Age maupun Amount_spent. Karena skala Amount_spent lebih besar dibanding fitur lain, standarisasi tetap diperlukan.

BAB III

DATA PREPARATION

Tahap Data Preparation menyiapkan data agar dapat digunakan oleh K-Means. Pada tahap ini tidak ada target, tidak ada pelabelan, dan tidak ada pembagian data latih/uji karena proyek bersifat clustering unsupervised.

3.1 Seleksi Atribut untuk Clustering

```
# =====
# KODE 3.1 SELEKSI ATRIBUT UNTUK CLUSTERING
# =====
fitur_model = ["Age", "Gender", "Marital_status", "Employees_status", "Payment_method", "Referral", "Amount_spent"]
fitur_profiling = ["Segment", "State_names", "Transaction_date"]
fitur_dibuang = ["Transaction_ID"]

fitur_tabel = pd.DataFrame({
    "Kelompok": ["Modeling"] * len(fitur_model) + ["Profiling"] * len(fitur_profiling) + ["Dibuang"] * len(fitur_dibuang),
    "Atribut": fitur_model + fitur_profiling + fitur_dibuang
})
display(fitur_tabel)
```

Kode 3.1 Seleksi Atribut untuk Clustering

Tabel 3.1 Seleksi Atribut untuk Clustering

	Kelompok	Atribut
0	Modeling	Age
1	Modeling	Gender
2	Modeling	Marital_status
3	Modeling	Employees_status
4	Modeling	Payment_method
5	Modeling	Referral
6	Modeling	Amount_spent
7	Profiling	Segment
8	Profiling	State_names
9	Profiling	Transaction_date
10	Dibuang	Transaction_ID

Fitur model terdiri dari Age, Gender, Marital_status, Employees_status, Payment_method, Referral, dan Amount_spent. Segment, State_names, dan Transaction_date dipakai untuk profiling, sedangkan Transaction_ID dibuang.

3.2 Penanganan Missing Value dan Pembersihan Data

```
# =====
# KODE 3.2 PENANGANAN MISSING VALUE DAN PEMBERSIHAN DATA
# =====
df_clean = df.copy()

# Amount_spent adalah fitur inti, sehingga baris kosong pada kolom ini dihapus.
jumlah_awal = len(df_clean)
df_clean = df_clean.dropna(subset=["Amount_spent"]).copy()
jumlah_setelah_drop = len(df_clean)

median_age = df_clean["Age"].median()
```

```

modus_referral = df_clean["Referral"].mode(dropna=True).iloc[0]

df_clean["Age"] = df_clean["Age"].fillna(median_age)
df_clean["Referral"] = df_clean["Referral"].fillna(modus_referral)
df_clean["Gender"] = df_clean["Gender"].fillna("Unknown")
df_clean["Employees_status"] = df_clean["Employees_status"].fillna("Unknown")

print("Jumlah data awal:", jumlah_awal)
print("Jumlah data setelah Amount_spent kosong dihapus:", jumlah_setelah_drop)
print("Jumlah baris terhapus:", jumlah_awal - jumlah_setelah_drop)
print("Median Age untuk imputasi:", median_age)
print("Modus Referral untuk imputasi:", modus_referral)
print("Missing value akhir pada fitur model:")
display(df_clean[fitur_model].isnull().sum().to_frame("Missing"))

```

Kode 3.2 Penanganan Missing Value dan Pembersihan Data

Tabel 3.2 Output Penanganan Missing Value

```

Jumlah data awal: 1000000
Jumlah data setelah Amount_spent kosong dihapus: 903935
Jumlah baris terhapus: 96065
Median Age untuk imputasi: 47.0
Modus Referral untuk imputasi: 1.0

```

Komponen	Hasil
Jumlah data awal	1,000,000
Jumlah data setelah Amount_spent kosong dihapus	903,935
Jumlah baris terhapus	96,065
Median Age untuk imputasi	47.00
Modus Referral untuk imputasi	1.00

Tabel 3.3 Missing Value Akhir pada Fitur Model

Missing value akhir pada fitur model:

	Missing
Age	0
Gender	0
Marital_status	0
Employees_status	0
Payment_method	0
Referral	0
Amount_spent	0

Baris dengan Amount_spent kosong dihapus karena Amount_spent merupakan fitur inti. Missing value pada Age diisi median 47,0, Referral diisi modus 1,0, sedangkan Gender dan Employees_status diisi Unknown.

3.3 Pseudo-Missing, Outlier, dan Konsistensi Kategori

```

# =====
# KODE 3.3 PEMERIKSAAN PSEUDO-MISSING, OUTLIER, DAN KONSISTENSI KATEGORI
# =====
print("Distribusi Segment setelah pembersihan utama:")
display(df_clean["Segment"].value_counts(dropna=False).to_frame("Jumlah"))

outlier_setelah = pd.DataFrame([cek_outlier_iqr(df_clean, "Age"), cek_outlier_iqr(df_clean, "Amount_spent")])
print("Outlier setelah pembersihan utama:")
display(outlier_setelah)

```

```

kolom_string = ["Gender", "Marital_status", "State_names", "Segment", "Employees_status", "Payment_method"]
for kolom in kolom_string:
    df_clean[kolom] = df_clean[kolom].astype(str).str.strip()

mapping_employees = {
    "workers": "Workers",
    "self-employed": "Self-Employed",
    "Employees": "Employees",
    "Unemployment": "Unemployment",
    "Unknown": "Unknown"
}
df_clean["Employees_status"] = df_clean["Employees_status"].replace(mapping_employees)

print("Distribusi Employees_status setelah konsistensi kategori:")
display(df_clean["Employees_status"].value_counts(dropna=False).to_frame("Jumlah"))

```

Kode 3.3 Pemeriksaan Pseudo-Missing, Outlier, dan Konsistensi Kategori

Tabel 3.4 Distribusi Segment Setelah Pembersihan Utama

Distribusi Segment setelah pembersihan utama:	
	Jumlah
Segment	
Basic	414486
Silver	172067
Platinum	156826
Gold	87659
Missing	72897

Tabel 3.5 Outlier Setelah Pembersihan Utama

Outlier setelah pembersihan utama:							
	Atribut	Q1	Q3	IQR	Batas Bawah	Batas Atas	Jumlah Outlier
0	Age	32.00	62.00	30.00	-13.00	107.00	0
1	Amount_spent	677.36	2037.59	1360.23	-1362.98	4077.94	0

Tabel 3.6 Distribusi Employees_status Setelah Konsistensi Kategori

Distribusi Employees_status setelah konsistensi kategori:	
	Jumlah
Employees_status	
Employees	342531
Workers	285418
Self-Employed	178236
Unemployment	87906
Unknown	9844

Nilai Segment Missing tidak diimputasi karena Segment tidak digunakan sebagai fitur model. Kategori Employees_status diseragamkan menjadi Employees, Workers, Self-Employed, Unemployment, dan Unknown.

3.4 Transformasi Tanggal, Encoding, Standardisasi, dan Simpan Preprocessor

```
# =====
# KODE 3.4 TRANSFORMASI TANGGAL, ENCODING, STANDARDISASI, DAN SIMPAN PREPROCESSOR
# =====
df_clean["Transaction_date"] = pd.to_datetime(df_clean["Transaction_date"], errors="coerce")
df_clean["Year"] = df_clean["Transaction_date"].dt.year
df_clean["Month"] = df_clean["Transaction_date"].dt.month
df_clean["DayOfWeek"] = df_clean["Transaction_date"].dt.day_name()

fitur_numerik = ["Age", "Referral", "Amount_spent"]
fitur_kategorikal = ["Gender", "Marital_status", "Employees_status", "Payment_method"]
X_raw = df_clean[fitur_numerik + fitur_kategorikal].copy()

try:
    encoder = OneHotEncoder(handle_unknown="ignore", sparse_output=False)
except TypeError:
    encoder = OneHotEncoder(handle_unknown="ignore", sparse=False)

preprocessor = ColumnTransformer(
    transformers=[
        ("num", StandardScaler(), fitur_numerik),
        ("cat", encoder, fitur_kategorikal)
    ],
    remainder="drop"
)

X_clustering_array = preprocessor.fit_transform(X_raw)
nama_fitur_akhir = preprocessor.get_feature_names_out()
X_clustering = pd.DataFrame(X_clustering_array, columns=nama_fitur_akhir)

joblib.dump(preprocessor, "preprocessor_clustering.pkl")

print("Ukuran dataset akhir untuk clustering:", X_clustering.shape)
print("Total missing pada dataset akhir:", int(X_clustering.isnull().sum().sum()))
print("Preprocessor disimpan sebagai preprocessor_clustering.pkl")
display(X_clustering.head())
```

Kode 3.4 Transformasi Tanggal, Encoding, Standardisasi, dan Simpan Preprocessor

Tabel 3.7 Output Transformasi dan Standardisasi

```
Ukuran dataset akhir untuk clustering: (903935, 16)
Total missing pada dataset akhir: 0
Preprocessor disimpan sebagai preprocessor_clustering.pkl
```

Tabel 3.8 Lima Baris Pertama Data Siap Clustering

num_Age	num_Referral	num_Amount_spent	cat_Gender_Female	cat_Gender_Male	cat_Gender_Unknown	cat_Marital_Married	cat_Marital_Single	cat_Employees_status_Employees	cat_Employees_status_Self-Employed	cat_Employees_status_Unemployment	cat_Employees_status_Unknown	cat_Employees_status_Workers	cat_Payment_method_Card	cat_Payment_method_Other	cat_Payment_method_PayPal
-0.4318	-1.43	0.1610	1.00	0.00	0.00	0.00	1.00	0.00	0.00	1.00	0.00	0.00	1.00	0.00	0.00
-0.7091	0.6986	-1.44	0.00	1.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	1.00
0.3446	0.6986	1.39	1.00	0.00	0.00	1.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	1.00
-0.7645	0.6986	-1.28	0.00	1.00	0.00	1.00	0.00	0.00	1.00	0.00	0.00	0.00	1.00	0.00	0.00
-0.5981	-1.43	0.2185	1.00	0.00	0.00	1.00	0.00	1.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00

Kode 3.4 menghasilkan 16 fitur numerik yang terdiri dari tiga fitur numerik terstandarisasi dan fitur dummy hasil One-Hot Encoding. File preprocessor_clustering.pkl disimpan untuk deployment.

3.5 Ekspor Dataset Hasil Data Preparation

```
# =====
# KODE 3.5 EKSPOR DATASET HASIL DATA PREPARATION
# =====
X_clustering.to_csv("data_clustering_prepared.csv", index=False)

data_profiling = df_clean[[
    "Transaction_ID", "Transaction_date", "Age", "Gender", "Marital_status",
```

```

"Employees_status", "Payment_method", "Referral", "Amount_spent",
"Segment", "State_names", "Year", "Month", "DayOfWeek"
]).copy()

data_profiling.to_csv("data_clustering_profile.csv", index=False)

ringkasan_akhir_bab3 = pd.DataFrame({
    "Komponen": ["Data awal", "Data akhir", "Fitur sebelum encoding", "Fitur setelah encoding", "Target/label", "Train-test split"],
    "Hasil": [f"{shape_awal[0]:,} baris x {shape_awal[1]} kolom", f"{X_clustering.shape[0]:,} baris x {X_clustering.shape[1]} fitur", len(fitur_model),
X_clustering.shape[1], "Tidak ada", "Tidak dilakukan"]
})
display(ringkasan_akhir_bab3)
print("File berhasil dibuat: data_clustering_prepared.csv, data_clustering_profile.csv")

```

Kode 3.5 Ekspor Dataset Hasil Data Preparation

Tabel 3.9 Ringkasan Akhir Data Preparation

	Komponen	Hasil
0	Data awal	1,000,000 baris x 11 kolom
1	Data akhir	903,935 baris x 16 fitur
2	Fitur sebelum encoding	7
3	Fitur setelah encoding	16
4	Target/label	Tidak ada
5	Train-test split	Tidak dilakukan

Tabel 3.10 File Output Data Preparation

Nama File	Ukuran	Kegunaan
data_clustering_prepared.csv	903.935 baris x 16 fitur	Input numerik untuk K-Means
data_clustering_profile.csv	903.935 baris x 14 kolom	Data pendamping untuk profiling cluster

Output BAB III menjadi input langsung untuk BAB IV. File data_clustering_prepared.csv digunakan untuk training, sedangkan data_clustering_profile.csv digunakan untuk interpretasi hasil cluster.

BAB IV MODELING

Tahap Modeling membentuk model clustering berdasarkan dataset hasil Data Preparation. Notebook final menggunakan K-Means sebagai algoritma utama dan menguji kandidat K dari 2 sampai 10.

4.1 Penentuan Kandidat Jumlah Cluster

```
# =====  
# KODE 4.1 PENENTUAN KANDIDAT JUMLAH CLUSTER  
# =====  
X = X_clustering.copy()  
profile = data_profiling.copy()  
  
X_sample = X.sample(n=min(100000, len(X)), random_state=RANDOM_STATE)  
X_metric = X_sample.sample(n=min(10000, len(X_sample)), random_state=RANDOM_STATE)  
  
hasil_k = []  
for k in range(2, 11):  
    model_k = KMeans(n_clusters=k, random_state=RANDOM_STATE, n_init=10, max_iter=300)  
    model_k.fit(X_sample)  
    label_metric = model_k.predict(X_metric)  
    hasil_k.append({  
        "k": k,  
        "inertia": model_k.inertia_,  
        "silhouette": silhouette_score(X_metric, label_metric, sample_size=min(5000, len(X_metric))), random_state=RANDOM_STATE),  
        "davies_bouldin": davies_bouldin_score(X_metric, label_metric),  
        "calinski_harabasz": calinski_harabasz_score(X_metric, label_metric)  
    })  
  
hasil_k = pd.DataFrame(hasil_k)  
display(hasil_k)  
hasil_k.to_csv("bab4_k_selection_results.csv", index=False)
```

Kode 4.1 Penentuan Kandidat Jumlah Cluster

Tabel 4.1 Hasil Pengujian Jumlah Cluster K=2 sampai K=10

	k	inertia	silhouette	davies_bouldin	calinski_harabasz
0	2	433809.171063	0.203303	1.925816	2325.376559
1	3	383208.825876	0.160556	2.012923	1968.709253
2	4	349506.584267	0.143652	1.782924	1755.796412
3	5	325904.369135	0.150124	1.996152	1592.022516
4	6	310026.073369	0.134925	2.047446	1446.113455
5	7	294520.863814	0.139660	1.922028	1360.922511
6	8	283019.355055	0.136432	1.957091	1268.522524
7	9	274326.478333	0.134167	2.010814	1181.993233
8	10	265814.233733	0.130103	2.045191	1118.128817

Pengujian menggunakan sample data untuk menjaga proses tetap efisien dan reproducible. Metrik yang dihitung adalah inertia, silhouette, Davies-Bouldin, dan Calinski-Harabasz.

4.2 Visualisasi Elbow, Silhouette, dan Davies-Bouldin


```
# =====  
# KODE 4.2 VISUALISASI ELBOW, SILHOUETTE, DAN DAVIES-BOULDIN  
# =====  
plt.figure(figsize=(8, 5))  
plt.plot(hasil_k["k"], hasil_k["inertia"], marker="o")
```

```
plt.title("Elbow Method untuk Penentuan Jumlah Cluster")
plt.xlabel("Jumlah Cluster (K)")
plt.ylabel("Inertia / WCSS")
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.savefig("fig_bab4_elbow.png", dpi=180)
plt.show()


plt.figure(figsize=(8, 5))
plt.plot(hasil_k["k"], hasil_k["silhouette"], marker="o")
plt.title("Silhouette Analysis untuk Penentuan Jumlah Cluster")
plt.xlabel("Jumlah Cluster (K)")
plt.ylabel("Silhouette Score")
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.savefig("fig_bab4_silhouette.png", dpi=180)
plt.show()

plt.figure(figsize=(8, 5))
plt.plot(hasil_k["k"], hasil_k["davies_bouldin"], marker="o")
plt.title("Davies-Bouldin Index untuk Alternatif Jumlah Cluster")
plt.xlabel("Jumlah Cluster (K)")
plt.ylabel("Davies-Bouldin Index")
plt.grid(True, linestyle="--", alpha=0.6)
plt.tight_layout()
plt.savefig("fig_bab4_dbi.png", dpi=180)
plt.show()
```


Kode 4.2 Visualisasi Elbow, Silhouette, dan Davies-Bouldin



Gambar 4.1 Grafik Elbow Method



Gambar 4.2 Grafik Silhouette Analysis



Gambar 4.3 Grafik Davies-Bouldin Index

Silhouette tertinggi berada pada K=2, tetapi K=4 dipilih karena Davies-Bouldin Index lebih baik untuk alternatif segmentasi yang lebih berguna secara bisnis dan masih dapat diinterpretasikan.

4.3 Pelatihan Model K-Means Akhir K=4

```
# =====
# KODE 4.3 PELATIHAN MODEL K-MEANS AKHIR K=4
# =====
k_final = 4
kmeans_final = KMeans(n_clusters=k_final, random_state=RANDOM_STATE, n_init=10, max_iter=300)
cluster_labels = kmeans_final.fit_predict(X)

print("Jumlah cluster akhir:", k_final)
print("Inertia/WCSS model akhir:", kmeans_final.inertia_)
print("Distribusi cluster:")
print(pd.Series(cluster_labels).value_counts().sort_index())
```

Kode 4.3 Pelatihan Model K-Means Akhir K=4

Tabel 4.2 Output Pelatihan Model Akhir

```
Jumlah cluster akhir: 4
Inertia/WCSS model akhir: 3159748.988599972
```

Tabel 4.3 Distribusi Cluster

```
Distribusi cluster:
0    196746
1    190219
2    296471
3    220499
Name: count, dtype: int64
```

4.4 Evaluasi Internal Model Akhir dan Distribusi Cluster

```
# =====
# KODE 4.4 EVALUASI INTERNAL MODEL AKHIR DAN DISTRIBUSI CLUSTER
# =====
eval_idx = X.sample(n=min(10000, len(X)), random_state=RANDOM_STATE).index
X_eval = X.loc[eval_idx]
labels_eval = cluster_labels[eval_idx]

final_metrics = pd.DataFrame({
    "Jumlah Cluster (K)": k_final,
    "Inertia/WCSS": kmeans_final.inertia_,
    "Silhouette Score (sample 10.000)": silhouette_score(X_eval, labels_eval, sample_size=min(5000, len(X_eval)), random_state=RANDOM_STATE),
    "Davies-Bouldin Index (sample 10.000)": davies_bouldin_score(X_eval, labels_eval),
    "Calinski-Harabasz Index (sample 10.000)": calinski_harabasz_score(X_eval, labels_eval)
})
display(final_metrics)
final_metrics.to_csv("bab4_final_model_metrics.csv", index=False)

profile_cluster = profile.copy()
profile_cluster["Cluster"] = cluster_labels

cluster_size = profile_cluster["Cluster"].value_counts().sort_index().rename("Jumlah").to_frame()
cluster_size["Persentase (%)"] = (cluster_size["Jumlah"] / len(profile_cluster) * 100).round(2)
display(cluster_size)
cluster_size.to_csv("bab4_cluster_size.csv")

plt.figure(figsize=(8, 5))
plt.bar(cluster_size.index.astype(str), cluster_size["Jumlah"])
plt.title("Jumlah Transaksi pada Setiap Cluster")
plt.xlabel("Cluster")
plt.ylabel("Jumlah Transaksi")
```


```
plt.tight_layout()
plt.savefig("fig_bab4_cluster_size.png", dpi=180)
plt.show()
```

Kode 4.4 Evaluasi Internal Model Akhir dan Distribusi Cluster

Tabel 4.4 Metrik Model Akhir K=4

Jumlah Cluster (K)	Inertia/WCSS	Silhouette Score (sample 10.000)	Davies-Bouldin Index (sample 10.000)	Calinski-Harabasz Index (sample 10.000)	
0	4	3.159749e+06	0.14647	1.772684	1762.958746

Cluster	Jumlah	Persentase (%)
0	196746	21.77
1	190219	21.04
2	296471	32.80
3	220499	24.39



Gambar 4.4 Jumlah Transaksi pada Setiap Cluster

Model akhir menggunakan seluruh data hasil preparation berjumlah 903.935 transaksi. Label cluster kemudian digabungkan ke data profiling untuk analisis karakteristik cluster.

4.5 Ringkasan Awal Profil Cluster, PCA, dan Simpan Output Modeling

```
# =====
```

```
# KODE 4.5 RINGKASAN AWAL PROFIL CLUSTER, PCA, DAN SIMPAN OUTPUT MODELING
# =====
ringkasan = []
for c in sorted(profile_cluster["Cluster"].unique()):
    data_c = profile_cluster[profile_cluster["Cluster"] == c]
    ringkasan.append({
        "Cluster": c,
        "Jumlah Transaksi": len(data_c),
        "Persentase (%)": round(len(data_c) / len(profile_cluster) * 100, 2),
        "Rata-rata Age": round(data_c["Age"].mean(), 2),
        "Median Age": round(data_c["Age"].median(), 2),
        "Rata-rata Amount_spent": round(data_c["Amount_spent"].mean(), 2),
        "Median Amount_spent": round(data_c["Amount_spent"].median(), 2),
        "Referral dominan": data_c["Referral"].mode().iat[0],
        "Gender dominan": data_c["Gender"].mode().iat[0],
        "Marital dominan": data_c["Marital_status"].mode().iat[0],
        "Employees dominan": data_c["Employees_status"].mode().iat[0],
        "Payment dominan": data_c["Payment_method"].mode().iat[0],
        "Segment bawaan dominan": data_c["Segment"].mode().iat[0],
        "State dominan": data_c["State_names"].mode().iat[0]
    })

cluster_profile_summary = pd.DataFrame(ringkasan)
display(cluster_profile_summary)
cluster_profile_summary.to_csv("bab4_cluster_profile_summary.csv", index=False)

viz_idx = X.sample(n=min(10000, len(X)), random_state=RANDOM_STATE).index
pca = PCA(n_components=2, random_state=RANDOM_STATE)
pcs = pca.fit_transform(X.loc[viz_idx])

viz = pd.DataFrame({"PC1": pcs[:, 0], "PC2": pcs[:, 1], "Cluster": cluster_labels[viz_idx].astype(str)})
plt.figure(figsize=(8, 6))
for cl in sorted(viz["Cluster"].unique()):
    sub = viz[viz["Cluster"] == cl]
    plt.scatter(sub["PC1"], sub["PC2"], s=8, alpha=0.5, label=f"Cluster {cl}")
plt.title("Visualisasi Cluster Menggunakan PCA 2D (Sample 10.000)")
plt.xlabel(f"PC1 ({pca.explained_variance_ratio_[0]*100:.2f}% var.)")
plt.ylabel(f"PC2 ({pca.explained_variance_ratio_[1]*100:.2f}% var.)")
plt.legend(markerscale=2)
plt.tight_layout()
plt.savefig("fig_bab4_pca_cluster.png", dpi=180)
plt.show()


profile_cluster.to_csv("data_clustering_profile_with_cluster.csv", index=False)
pd.DataFrame(kmeans_final.cluster_centers_, columns=X.columns).to_csv("bab4_kmeans_centroids.csv", index=False)
joblib.dump(kmeans_final, "model_kmeans_clustering_k4.pkl")

print("Output modeling berhasil disimpan.")
```

Kode 4.5 Ringkasan Awal Profil Cluster, PCA, dan Simpan Output Modeling

Tabel 4.5 Ringkasan Awal Profil Cluster

	Cluster	Jumlah Transaksi	Persentase (%)	Rata-rata Age	Median Age	Rata-rata Amount_spent	Median Amount_spent	Referral dominan	Gender dominan	Marital dominan	Employees dominan	Payment dominan	Segment bawaan dominan	State dominan
0	0	196746	21.77	46.45	47.0	2461.06	2568.34	1.0	Female	Married	Employees	PayPal	Basic	Illinois
1	1	190219	21.04	29.47	29.0	904.27	904.22	1.0	Female	Married	Employees	PayPal	Basic	Florida
2	2	296471	32.80	46.51	47.0	1428.84	1396.59	0.0	Female	Married	Employees	PayPal	Basic	Kentucky
3	3	220499	24.39	62.39	63.0	908.23	875.44	1.0	Female	Married	Workers	PayPal	Basic	Georgia



Gambar 4.5 Visualisasi Cluster Menggunakan PCA 2D

Tabel 4.6 Centroid K-Means Final

Cluster	num_Age	num_Referral	num_Amount_spent	cat_Gender_Female	cat_Gender_Male	cat_Gender_Unknown	cat_Marital_status_Married	cat_Marital_status_Single	cat_Employees_status_Employees	cat_Employees_status_Self-Employed	cat_Employees_status_Unemployment	cat_Employees_status_Unknown	cat_Employees_status_Workers	cat_Payment_method_Card	cat_Payment_method_Other	cat_Payment_method_PayPal
0.00	-0.0187	0.6986	1.19	0.5307	0.4611	0.0082	0.5875	0.4125	0.4132	0.2037	0.0889	0.0021	0.2921	0.3029	0.2474	0.4497
1.00	-0.9601	0.6986	-0.5829	0.5196	0.4664	0.0140	0.5865	0.4135	0.3783	0.2153	0.1164	0.0144	0.2757	0.3315	0.2198	0.4487
2.00	-0.0151	-1.43	0.0145	0.5727	0.4152	0.0121	0.5779	0.4221	0.3835	0.2015	0.0918	0.0174	0.3058	0.3135	0.2200	0.4665
3.00	0.8653	0.6986	-0.5784	0.5057	0.4835	0.0109	0.5953	0.4047	0.3427	0.1699	0.0956	0.0069	0.3849	0.2301	0.2784	0.4916

Output modeling yang disimpan adalah data_clustering_profile_with_cluster.csv, bab4_kmeans_centroids.csv, dan model_kmeans_clustering_k4.pkl. File model akan digunakan pada tahap deployment.

BAB V EVALUATION

Tahap Evaluation menilai kualitas hasil clustering melalui metrik internal, visualisasi, serta profiling karakteristik setiap cluster. Bagian profiling merupakan inti evaluasi clustering karena tidak terdapat label aktual untuk dihitung sebagai akurasi.

5.1 Ringkasan Metrik Internal

```
# =====
# KODE 5.1 RINGKASAN METRIK INTERNAL
# =====
internal_metrics = pd.DataFrame({
    "Metrik": ["Inertia/WCSS", "Silhouette Score (sample 10.000)", "Davies-Bouldin Index (sample 10.000)", "Calinski-Harabasz Index (sample 10.000)"],
    "Nilai": [
        float(final_metrics["Inertia/WCSS"].iloc[0]),
        float(final_metrics["Silhouette Score (sample 10.000)"].iloc[0]),
        float(final_metrics["Davies-Bouldin Index (sample 10.000)"].iloc[0]),
        float(final_metrics["Calinski-Harabasz Index (sample 10.000)"].iloc[0])
    ],
    "Interpretasi Singkat": [
        "Semakin kecil semakin baik untuk kompaksi cluster pada K-Means.",
        "Nilai mendekati 1 semakin baik; hasil menunjukkan pemisahan cluster belum sangat kuat.",
        "Semakin kecil semakin baik; digunakan sebagai salah satu dasar memilih K=4.",
        "Semakin besar semakin baik; digunakan sebagai metrik pendukung."
    ]
})
display(internal_metrics)
internal_metrics.to_csv("bab5_internal_metrics_summary.csv", index=False)
```

Kode 5.1 Ringkasan Metrik Internal

Tabel 5.1 Ringkasan Metrik Internal

	Metrik	Nilai	Interpretasi Singkat
0	Inertia/WCSS	3.159749e+06	Semakin kecil semakin baik untuk kompaksi clus...
1	Silhouette Score (sample 10.000)	1.464697e-01	Nilai mendekati 1 semakin baik; hasil menunjuk...
2	Davies-Bouldin Index (sample 10.000)	1.772684e+00	Semakin kecil semakin baik; digunakan sebagai ...
3	Calinski-Harabasz Index (sample 10.000)	1.762959e+03	Semakin besar semakin baik; digunakan sebagai ...

Metrik	Nilai	Interpretasi Singkat
Inertia/WCSS	3,159,748.99	Semakin kecil semakin baik untuk kompaksi cluster pada K-Means.
Silhouette Score (sample 10.000)	0.1465	Nilai mendekati 1 semakin baik; hasil menunjukkan pemisahan cluster belum sangat kuat.
Davies-Bouldin Index (sample 10.000)	1.77	Semakin kecil semakin baik; digunakan sebagai salah satu dasar memilih K=4.
Calinski-Harabasz Index (sample 10.000)	1,762.96	Semakin besar semakin baik; digunakan sebagai metrik pendukung.

Nilai Silhouette Score 0,1465 menunjukkan pemisahan cluster belum sangat kuat secara geometris. Namun, hasil masih dapat dianalisis karena profil cluster menunjukkan perbedaan karakteristik yang jelas.

5.2 Visualisasi Cluster untuk Evaluation

```
# =====
# KODE 5.2 VISUALISASI CLUSTER UNTUK EVALUATION
# =====
plt.figure(figsize=(8, 5))
```



```

plt.bar(cluster_size.index.astype(str), cluster_size["Jumlah"])
plt.title("Jumlah Transaksi pada Setiap Cluster")
plt.xlabel("Cluster")
plt.ylabel("Jumlah Transaksi")
plt.tight_layout()
plt.savefig("fig_bab5_cluster_size.png", dpi=180)
plt.show()


amount_summary = profile_cluster.groupby("Cluster")["Amount_spent"].mean().round(2)
plt.figure(figsize=(8, 5))
plt.bar(amount_summary.index.astype(str), amount_summary.values)
plt.title("Rata-rata Amount_spent per Cluster")
plt.xlabel("Cluster")
plt.ylabel("Rata-rata Amount_spent")
plt.tight_layout()
plt.savefig("fig_bab5_avg_amount.png", dpi=180)
plt.show()

age_summary = profile_cluster.groupby("Cluster")["Age"].mean().round(2)
plt.figure(figsize=(8, 5))
plt.bar(age_summary.index.astype(str), age_summary.values)
plt.title("Rata-rata Age per Cluster")
plt.xlabel("Cluster")
plt.ylabel("Rata-rata Age")
plt.tight_layout()
plt.savefig("fig_bab5_avg_age.png", dpi=180)
plt.show()


# PCA untuk BAB V memakai sampel yang sama konsepnya dengan BAB IV
plt.figure(figsize=(8, 6))
for cl in sorted(viz["Cluster"].unique()):
    sub = viz[viz["Cluster"] == cl]
    plt.scatter(sub["PC1"], sub["PC2"], s=8, alpha=0.5, label=f"Cluster {cl}")
plt.title("Visualisasi Cluster Menggunakan PCA 2D (Sample 10.000)")
plt.xlabel(f"PC1 ({pca.explained_variance_ratio_[0]*100:.2f}% var.)")
plt.ylabel(f"PC2 ({pca.explained_variance_ratio_[1]*100:.2f}% var.)")
plt.legend(markerscale=2)
plt.tight_layout()
plt.savefig("fig_bab5_pca_cluster.png", dpi=180)
plt.show()

```


Kode 5.2 Visualisasi Cluster untuk Evaluation




Gambar 5.1 Jumlah Transaksi pada Setiap Cluster



Gambar 5.2 Rata-rata Amount_spent per Cluster



Gambar 5.3 Rata-rata Age per Cluster



Gambar 5.4 Visualisasi Cluster Menggunakan PCA 2D

5.3 Profiling Numerik dan Kategorikal Setiap Cluster

```
# =====
# KODE 5.3 PROFILING NUMERIK DAN KATEGORIKAL SETIAP CLUSTER
# =====
numeric_profile = profile_cluster.groupby("Cluster").agg(
    Jumlah_Transaksi=("Transaction_ID", "count"),
    Rata_rata_Age=("Age", "mean"),
    Median_Age=("Age", "median"),
    Rata_rata_Amount_spent=("Amount_spent", "mean"),
    Median_Amount_spent=("Amount_spent", "median"),
    Rata_rata_Referral=("Referral", "mean")
).round(2).reset_index()

display(numeric_profile)
numeric_profile.to_csv("bab5_numeric_profile_summary.csv", index=False)

def mode_value(s):
    return s.mode().iat[0] if not s.mode().empty else None

dominant_category = profile_cluster.groupby("Cluster").agg(
    Gender_Dominan=("Gender", mode_value),
    Marital_Dominan=("Marital_status", mode_value),
    Employees_Dominan=("Employees_status", mode_value),
    Payment_Dominan=("Payment_method", mode_value),
    Segment_Bawaan_Dominan=("Segment", mode_value),
    State_Dominan=("State_names", mode_value)
).reset_index()

display(dominant_category)
dominant_category.to_csv("bab5_dominant_category_profile.csv", index=False)
```

Kode 5.3 Profiling Numerik dan Kategorikal Setiap Cluster

Tabel 5.2 Profil Numerik Cluster

	Cluster	Jumlah_Transaksi	Rata_rata_Age	Median_Age	Rata_rata_Amount_spent	Median_Amount_spent	Rata_rata_Referral
0	0	196746	46.45	47.0	2461.06	2568.34	1.0
1	1	190219	29.47	29.0	904.27	904.22	1.0
2	2	296471	46.51	47.0	1428.84	1396.59	0.0
3	3	220499	62.39	63.0	908.23	875.44	1.0

Tabel 5.3 Profil Kategori Dominan Setiap Cluster

	Cluster	Gender_Dominan	Marital_Dominan	Employees_Dominan	Payment_Dominan	Segment_Bawaan_Dominan	State_Dominan
0	0	Female	Married	Employees	PayPal	Basic	Illinois
1	1	Female	Married	Employees	PayPal	Basic	Florida
2	2	Female	Married	Employees	PayPal	Basic	Kentucky
3	3	Female	Married	Workers	PayPal	Basic	Georgia

Cluster 0 memiliki rata-rata pengeluaran tertinggi, Cluster 1 memiliki rata-rata usia termuda, Cluster 2 merupakan cluster terbesar dan didominasi transaksi tanpa referral, sedangkan Cluster 3 memiliki rata-rata usia tertinggi.

5.4 Interpretasi dan Rekomendasi Awal Tiap Cluster

```
# =====
# KODE 5.4 INTERPRETASI DAN REKOMENDASI AWAL TIAP CLUSTER
# =====
interpretation = pd.DataFrame([
    [0, "Transaksi high value dengan referral", "Pengeluaran tertinggi dan seluruhnya didominasi referral", "Pertahankan loyalitas, tawarkan program premium atau bundling produk"],
    [1, "Transaksi pelanggan muda berpengeluaran rendah", "Usia rata-rata paling muda dengan pengeluaran rendah", "Gunakan voucher, cashback, dan rekomendasi produk terjangkau"],
    [2, "Transaksi non-referral berpengeluaran sedang", "Cluster terbesar dan didominasi transaksi tanpa referral", "Dorong program referral dan retensi karena kelompok ini besar"],
    [3, "Transaksi usia senior berpengeluaran rendah", "Usia rata-rata paling tinggi dengan pengeluaran rendah", "Gunakan pendekatan layanan sederhana dan promo kebutuhan rutin"]
], columns=["Cluster", "Nama Profil", "Karakteristik Utama", "Rekomendasi Awal"])

display(interpretation)
interpretation.to_csv("bab5_cluster_interpretation_summary.csv", index=False)
print("Output evaluation berhasil disimpan.")
```

Kode 5.4 Interpretasi dan Rekomendasi Awal Tiap Cluster

Tabel 5.4 Interpretasi dan Rekomendasi Awal Tiap Cluster

Cluster		Nama Profil	Karakteristik Utama	Rekomendasi Awal
0	0	Transaksi high value dengan referral	Pengeluaran tertinggi dan seluruhnya didominasi...	Pertahankan loyalitas, tawarkan program premiu...
1	1	Transaksi pelanggan muda berpengeluaran rendah	Usia rata-rata paling muda dengan pengeluaran ...	Gunakan voucher, cashback, dan rekomendasi pro...
2	2	Transaksi non-referral berpengeluaran sedang	Cluster terbesar dan didominasi transaksi tanp...	Dorong program referral dan retensi karena kel...
3	3	Transaksi usia senior berpengeluaran rendah	Usia rata-rata paling tinggi dengan pengeluara...	Gunakan pendekatan layanan sederhana dan promo...

Output evaluation berhasil disimpan.

Cluster	Nama Profil	Karakteristik Utama	Rekomendasi Awal
0	Transaksi high value dengan referral	Pengeluaran tertinggi dan seluruhnya didominasi referral	Pertahankan loyalitas, tawarkan program premium atau bundling produk
1	Transaksi pelanggan muda	Usia rata-rata paling muda	Gunakan voucher, cashback, dan

Cluster	Nama Profil	Karakteristik Utama	Rekomendasi Awal
	berpengeluaran rendah	dengan pengeluaran rendah	rekomendasi produk terjangkau
2	Transaksi non-referral berpengeluaran sedang	Cluster terbesar dan didominasi transaksi tanpa referral	Dorong program referral dan retensi karena kelompok ini besar
3	Transaksi usia senior berpengeluaran rendah	Usia rata-rata paling tinggi dengan pengeluaran rendah	Gunakan pendekatan layanan sederhana dan promo kebutuhan rutin

Hasil evaluasi menunjukkan bahwa model K-Means K=4 dapat menghasilkan segmentasi yang dapat ditafsirkan sebagai dasar rekomendasi strategi pemasaran dan layanan.

BAB VI DEPLOYMENT

Tahap Deployment memanfaatkan hasil segmentasi dalam bentuk aplikasi sederhana berbasis Streamlit. Aplikasi menerima input transaksi baru, memproses input dengan preprocessor yang sama seperti BAB III, memprediksi cluster menggunakan model K-Means K=4, lalu menampilkan interpretasi dan rekomendasi awal berdasarkan hasil cluster.

6.1 Contoh Prediksi Cluster untuk Input Baru

```
# =====
# KODE 6.1 CONTOH PREDIKSI CLUSTER UNTUK INPUT BARU
# =====
# Input baru masih mentah sehingga harus diproses dengan preprocessor BAB III.
input_baru = pd.DataFrame({
    "Age": 35,
    "Gender": "Female",
    "Marital_status": "Married",
    "Employees_status": "Employees",
    "Payment_method": "PayPal",
    "Referral": 1.0,
    "Amount_spent": 1000.0
})

input_prepared_array = preprocessor.transform(input_baru)
input_prepared = pd.DataFrame(input_prepared_array, columns=preprocessor.get_feature_names_out())
cluster_prediksi = int(kmeans_final.predict(input_prepared)[0])

print("Input baru:")
display(input_baru)
print("Input setelah preprocessing:")
display(input_prepared)
print("Prediksi cluster:", cluster_prediksi)
print("Interpretasi cluster:")
display(interpretation[interpretation["Cluster"] == cluster_prediksi])
```

Kode 6.1 Contoh Prediksi Cluster untuk Input Baru

Tabel 6.1 Input Baru yang Diuji

Input baru:							
	Age	Gender	Marital_status	Employees_status	Payment_method	Referral	Amount_spent
0	35	Female	Married	Employees	PayPal	1.0	1000.0

Tabel 6.2 Input Baru Setelah Preprocessing

num_Age	num_Referral	num_Amount_spent	cat_Gender_Female	cat_Gender_Male	cat_Gender_Unknown	cat_Marital_status_Married	cat_Marital_status_Single	cat_Employees_status_Employees	cat_Employees_status_Self-Employed	cat_Employees_status_Unemployment	cat_Employees_status_Unknown	cat_Employees_status_Workers	cat_Payment_method_Card	cat_Payment_method_Other	cat_Payment_method_PayPal
-0.6536	0.6986	-0.4739	1.00	0.00	0.00	1.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00

Tabel 6.3 Hasil Prediksi Cluster Input Baru

Komponen	Hasil
Prediksi cluster	1

Tabel 6.4 Interpretasi Cluster Hasil Prediksi

Cluster	Nama Profil	Karakteristik Utama	Rekomendasi Awal
1	Transaksi pelanggan muda berpengeluaran rendah	Usia rata-rata paling muda dengan pengeluaran rendah	Gunakan voucher, cashback, dan rekomendasi produk terjangkau

Contoh input baru masuk ke Cluster 1. Hasil ini konsisten dengan file interpretasi cluster yang dihasilkan pada BAB V.

6.2 Membuat File Aplikasi Streamlit

```
# =====
# KODE 6.2 MEMBUAT FILE APLIKASI STREAMLIT
# =====
app_code = r"""
import os
import pandas as pd
import streamlit as st
import joblib

st.set_page_config(page_title="Deployment K-Means Clustering", layout="wide")

@st.cache_resource
def load_artifacts():
    model = joblib.load("model_kmeans_clustering_k4.pkl")
    preprocessor = joblib.load("preprocessor_clustering.pkl")
    interpretation = pd.read_csv("bab5_cluster_interpretation_summary.csv")
    numeric_profile = pd.read_csv("bab5_numeric_profile_summary.csv")
    return model, preprocessor, interpretation, numeric_profile

st.title("Deployment Segmentasi Pola Transaksi Pelanggan")
st.write("Aplikasi ini menggunakan model K-Means K=4 untuk menentukan cluster transaksi baru.")

required_files = [
    "model_kmeans_clustering_k4.pkl",
    "preprocessor_clustering.pkl",
    "bab5_cluster_interpretation_summary.csv",
    "bab5_numeric_profile_summary.csv"
]
missing_files = [f for f in required_files if not os.path.exists(f)]
if missing_files:
    st.error("File deployment belum lengkap. Upload file berikut ke folder aplikasi:")
    st.write(missing_files)
    st.stop()

model, preprocessor, interpretation, numeric_profile = load_artifacts()

st.subheader("Input Data Transaksi Baru")
col1, col2, col3 = st.columns(3)

with col1:
    age = st.number_input("Age", min_value=15, max_value=78, value=35)
    gender = st.selectbox("Gender", ["Female", "Male", "Unknown"])
    marital_status = st.selectbox("Marital Status", ["Married", "Single"])

with col2:
    employees_status = st.selectbox("Employees Status", ["Employees", "Self-Employed", "Unemployment", "Workers", "Unknown"])
    payment_method = st.selectbox("Payment Method", ["PayPal", "Card", "Other"])
    referral = st.selectbox("Referral", [0.0, 1.0], format_func=lambda x: "Ya" if x == 1.0 else "Tidak")
```

```

with col3:
    amount_spent = st.number_input("Amount Spent", min_value=0.0, max_value=5000.0, value=1000.0, step=10.0)

input_data = pd.DataFrame({
    "Age": age,
    "Gender": gender,
    "Marital_status": marital_status,
    "Employees_status": employees_status,
    "Payment_method": payment_method,
    "Referral": referral,
    "Amount_spent": amount_spent
})

if st.button("Prediksi Cluster"):
    input_prepared_array = preprocessor.transform(input_data)
    input_prepared = pd.DataFrame(input_prepared_array, columns=preprocessor.get_feature_names_out())
    cluster = int(model.predict(input_prepared)[0])

    st.success(f"Transaksi masuk ke Cluster {cluster}")
    hasil = interpretation[interpretation["Cluster"] == cluster]
    profil = numeric_profile[numeric_profile["Cluster"] == cluster]

    if not hasil.empty:
        st.subheader("Interpretasi Cluster")
        st.write("**Nama Profil:**", hasil.iloc[0]["Nama Profil"])
        st.write("**Karakteristik Utama:**", hasil.iloc[0]["Karakteristik Utama"])
        st.write("**Rekomendasi Awal:**", hasil.iloc[0]["Rekomendasi Awal"])

    if not profil.empty:
        st.subheader("Profil Numerik Cluster")
        st.dataframe(profil, use_container_width=True)

st.subheader("Ringkasan Profil Semua Cluster")
st.dataframe(interpretation, use_container_width=True)
"""

with open("app_streamlit_clustering.py", "w", encoding="utf-8") as f:
    f.write(app_code)

with open("requirements_deployment.txt", "w", encoding="utf-8") as f:
    f.write("streamlit\npandas\nscikit-learn\njoblib\nmatplotlib\n")

readme_text = """Panduan Deployment Streamlit\nFile wajib dalam folder yang sama:\n1. app_streamlit_clustering.py\n2. model_kmeans_clustering_k4.pkl\n3. preprocessor_clustering.pkl\n4. bab5_cluster_interpretation_summary.csv\n5. bab5_numeric_profile_summary.csv\n6. requirements_deployment.txt\nCara menjalankan:\npip install -r requirements_deployment.txt\nstreamlit run app_streamlit_clustering.py\nCatatan:\npreprocessor_clustering.pkl wajib ada karena input baru harus diubah ke format 16 fitur numerik yang sama seperti data training.\n"""
with open("README_deployment.txt", "w", encoding="utf-8") as f:
    f.write(readme_text)

print("File deployment berhasil dibuat.")

```

Kode 6.2 Membuat File Aplikasi Streamlit

Tabel 6.5 File Deployment yang Dibuat

Output	Kegunaan
app_streamlit_clustering.py	Aplikasi demo Streamlit
requirements_deployment.txt	Daftar library deployment
README_deployment.txt	Panduan menjalankan deployment

Aplikasi Streamlit membutuhkan model_kmeans_clustering_k4.pkl, preprocessor_clustering.pkl, bab5_cluster_interpretation_summary.csv, dan bab5_numeric_profile_summary.csv agar dapat berjalan.

6.3 Gambar Alur Deployment dan Manifest Output

```

# =====
# KODE 6.3 GAMBAR ALUR DEPLOYMENT DAN MANIFEST OUTPUT
# =====
plt.figure(figsize=(10, 4))
plt.axis("off")

```

```

steps = [
    "Input transaksi baru",
    "Preprocessing\n(StandardScaler + One-Hot Encoding)",
    "Model K-Means K=4",
    "Cluster hasil prediksi",
    "Interpretasi & rekomendasi"
]
for i, step in enumerate(steps):
    x = 0.08 + i * 0.22
    plt.text(x, 0.55, step, ha="center", va="center", bbox=dict(boxstyle="round,pad=0.5", fc="white", ec="black"), fontsize=9)
    if i < len(steps)-1:
        plt.annotate("", xy=(x+0.1, 0.55), xytext=(x+0.15, 0.55), arrowprops=dict(arrowstyle="->", lw=1.5))
plt.title("Alur Deployment Hasil Clustering")
plt.tight_layout()
plt.savefig("fig_bab6_deployment_flow.png", dpi=180)
plt.show()

output_files = [
    ("fig_missing_values.png", "Visualisasi missing value BAB II"),
    ("fig_amount_boxplot.png", "Boxplot Amount_spent BAB II"),
    ("data_clustering_prepared.csv", "Dataset numerik siap modeling K-Means dari BAB III"),
    ("data_clustering_profile.csv", "Dataset bersih untuk profiling dari BAB III"),
    ("preprocessor_clustering.pkl", "Preprocessor untuk input baru pada deployment"),
    ("bab4_k_selection_results.csv", "Hasil uji K=2 sampai K=10"),
    ("bab4_final_model_metrics.csv", "Metrik model akhir K=4"),
    ("bab4_cluster_size.csv", "Jumlah transaksi per cluster"),
    ("bab4_cluster_profile_summary.csv", "Ringkasan awal profil cluster"),
    ("bab4_kmeans_centroids.csv", "Centroid model K-Means"),
    ("data_clustering_profile_with_cluster.csv", "Data profiling yang sudah memiliki kolom Cluster"),
    ("model_kmeans_clustering_k4.pkl", "Model K-Means final untuk deployment"),
    ("fig_bab4_elbow.png", "Grafik Elbow Method"),
    ("fig_bab4_silhouette.png", "Grafik Silhouette Analysis"),
    ("fig_bab4_dbi.png", "Grafik Davies-Bouldin Index"),
    ("fig_bab4_cluster_size.png", "Grafik ukuran cluster BAB IV"),
    ("fig_bab4_pca_cluster.png", "Visualisasi PCA BAB IV"),
    ("bab5_internal_metrics_summary.csv", "Ringkasan metrik internal BAB V"),
    ("bab5_numeric_profile_summary.csv", "Profil numerik cluster BAB V"),
    ("bab5_dominant_category_profile.csv", "Kategori dominan tiap cluster BAB V"),
    ("bab5_cluster_interpretation_summary.csv", "Interpretasi dan rekomendasi awal cluster"),
    ("fig_bab5_cluster_size.png", "Grafik jumlah transaksi per cluster BAB V"),
    ("fig_bab5_avg_amount.png", "Grafik rata-rata Amount_spent per cluster"),
    ("fig_bab5_avg_age.png", "Grafik rata-rata Age per cluster"),
    ("fig_bab5_pca_cluster.png", "Visualisasi PCA BAB V"),
    ("app_streamlit_clustering.py", "Aplikasi Streamlit untuk demo deployment"),
    ("requirements_deployment.txt", "Daftar library deployment"),
    ("README_deployment.txt", "Panduan menjalankan deployment"),
    ("fig_bab6_deployment_flow.png", "Gambar alur deployment")
]

manifest = pd.DataFrame(output_files, columns=["Nama File", "Kegunaan"])
manifest["Tersedia"] = manifest["Nama File"].apply(os.path.exists)
display(manifest)
manifest.to_csv("output_file_manifest.csv", index=False)

print("Manifest output disimpan sebagai output_file_manifest.csv")
print("Semua file utama tersedia:", manifest["Tersedia"].all())

```

Kode 6.3 Gambar Alur Deployment dan Manifest Output

Alur Deployment Hasil Clustering



Gambar 6.1 Alur Deployment Hasil Clustering

Tabel 6.6 Manifest Output Notebook Final

Nama File	Kegunaan	Tersedia
fig_missing_values.png	Visualisasi missing value BAB II	1
fig_amount_boxplot.png	Boxplot Amount_spent BAB II	1
data_clustering_prepared.csv	Dataset numerik siap modeling K-Means dari BAB III	1
data_clustering_profile.csv	Dataset bersih untuk profiling dari BAB III	1
preprocessor_clustering.pkl	Preprocessor untuk input baru pada deployment	1
bab4_k_selection_results.csv	Hasil uji K=2 sampai K=10	1
bab4_final_model_metrics.csv	Metrik model akhir K=4	1
bab4_cluster_size.csv	Jumlah transaksi per cluster	1
bab4_cluster_profile_summary.csv	Ringkasan awal profil cluster	1
bab4_kmeans_centroids.csv	Centroid model K-Means	1
data_clustering_profile_with_cluster.csv	Data profiling yang sudah memiliki kolom Cluster	1
model_kmeans_clustering_k4.pkl	Model K-Means final untuk deployment	1
fig_bab4_elbow.png	Grafik Elbow Method	1
fig_bab4_silhouette.png	Grafik Silhouette Analysis	1
fig_bab4_dbi.png	Grafik Davies-Bouldin Index	1
fig_bab4_cluster_size.png	Grafik ukuran cluster BAB IV	1
fig_bab4_pca_cluster.png	Visualisasi PCA BAB IV	1
bab5_internal_metrics_summary.csv	Ringkasan metrik internal BAB V	1
bab5_numeric_profile_summary.csv	Profil numerik cluster BAB V	1
bab5_dominant_category_profile.csv	Kategori dominan tiap cluster BAB V	1
bab5_cluster_interpretation_summary.csv	Interpretasi dan rekomendasi awal cluster	1
fig_bab5_cluster_size.png	Grafik jumlah transaksi per cluster BAB V	1
fig_bab5_avg_amount.png	Grafik rata-rata Amount_spent per cluster	1
fig_bab5_avg_age.png	Grafik rata-rata Age per cluster	1
fig_bab5_pca_cluster.png	Visualisasi PCA BAB V	1
app_streamlit_clustering.py	Aplikasi Streamlit untuk demo deployment	1
requirements_deployment.txt	Daftar library deployment	1
README_deployment.txt	Panduan menjalankan deployment	1
fig_bab6_deployment_flow.png	Gambar alur deployment	1

Output manifest menunjukkan bahwa seluruh file utama dari BAB II sampai BAB VI tersedia setelah notebook dijalankan. Hal ini mendukung reproducibility dan memudahkan demo pelatihan serta deployment.

6.4 Pemanfaatan Hasil Segmentasi

- Cluster 0: diprioritaskan untuk program loyalitas, bundling, dan penawaran premium karena memiliki pengeluaran tertinggi.
- Cluster 1: cocok untuk voucher, cashback, dan rekomendasi produk terjangkau karena mewakili pelanggan muda berpengeluaran rendah.
- Cluster 2: perlu didorong ke program referral dan retensi karena merupakan cluster terbesar dan didominasi transaksi tanpa referral.

- Cluster 3: cocok untuk layanan sederhana dan promosi kebutuhan rutin karena memiliki rata-rata usia tertinggi dengan pengeluaran rendah.

6.5 Keterbatasan

- Silhouette Score masih rendah sehingga pemisahan cluster tidak sepenuhnya kuat secara geometris.
- Dataset tidak memiliki Customer_ID, sehingga segmentasi dilakukan pada level transaksi, bukan pelanggan unik.
- Atribut Segment tidak digunakan sebagai fitur model karena merupakan segmentasi bawaan dataset.
- Deployment masih berupa aplikasi lokal Streamlit dan belum diintegrasikan dengan database atau sistem transaksi nyata.

DAFTAR PUSTAKA

mountboy. (2024). *Online Store Customer Transactions (1M rows)* (Version 1) [Data set]. Kaggle.
<https://www.kaggle.com/datasets/mountboy/online-store-customer-transactions-1m-rows/data>

LAMPIRAN

Link Repository GitHub: <https://github.com/Alex4625/uas-data-mining-clustering-kmeans>

Notebook bukti yang menjadi acuan sinkronisasi laporan:

https://colab.research.google.com/drive/1JTzT4HD9wx-528QoOKysoKNrGbEfyJ5z#scrollTo=w0IwoSrh_bNf